PROJETO SPRINT 3 (AC-3)

MACHINE LEARNING APLICADO À BIOMEDICINA

Documento de Escopo do Projeto Predição de Risco Clínico com Machine Learning

Disciplina: Machine Learning e Chatbot

Turmas: CDC e ADS

Professor: Flávio Santarelli

Valor total do projeto: até 1,0 ponto na nota da AC-3.

1. VISÃO GERAL DO PROJETO

O projeto tem como objetivo desenvolver um sistema funcional de predição de risco clínico por meio de técnicas de Machine Learning. A proposta simula um cenário real da área da saúde, no qual profissionais médicos e enfermeiros precisam analisar rapidamente diversos dados de pacientes para identificar potenciais riscos de doenças crônicas ou complicações.

O sistema atua como uma ferramenta de apoio à decisão clínica, reduzindo a subjetividade da análise manual e auxiliando na identificação precoce de padrões nos dados.

2. OBJETIVO PRINCIPAL

Construir um sistema completo que seja capaz de:

- Receber dados clínicos de um paciente (nome fictício, idade, glicose, pressão arterial, IMC e colesterol).
- Processar e normalizar essas informações.
- Gerar uma probabilidade de risco para cada classe.
- Classificar o paciente em uma das três categorias: Baixo, Médio ou Alto risco.

3. PROBLEMA DE NEGÓCIO

Na prática clínica, a análise simultânea de múltiplos fatores (idade, glicose, pressão arterial, IMC, colesterol etc.) é complexa e pode variar conforme a experiência do profissional. O sistema desenvolvido elimina essa subjetividade ao identificar automaticamente padrões nos dados, antecipar riscos e fornecer uma recomendação probabilística clara e reproduzível.

4. ENTREGÁVEIS OBRIGATÓRIOS

Para aprovação completa, cada aluno deve entregar:

1. Dataset gerado (sintético com no mínimo 2.000 registros).
2. Código completo e funcional (organizado em módulos).
3. Modelo de Machine Learning treinado.
4. Evidência de execução: pitch em vídeo de 3 minutos (máximo), contendo demonstração do sistema em funcionamento e explicação simples do que foi feito.

5. ETAPAS OBRIGATÓRIAS DO PROJETO

Etapa 1 — Dados:

Criar ou utilizar um dataset com as variáveis clínicas obrigatórias:

- Nome (fictício)
- Idade
- Glicose
- Pressão Arterial
- IMC
- Colesterol

Etapa 2 — Preparação

- Organização e limpeza dos dados
- Análise exploratória (EDA)
- Separação em conjuntos de treino e teste (recomendado 80/20)

Etapa 3 — Modelagem

Treinar um modelo de classificação multiclasse. Sugestões principais:

- Random Forest Classifier (recomendado)
- Regressão Logística Multinomial (baseline)

Etapa 4 — Avaliação Avaliar o modelo com as métricas:

- Acurácia

- Precisão
- Recall
- F1-score
- Matriz de confusão

Etapa 5 — Predição

Realizar teste com um novo paciente (dados simulados) e exibir probabilidade e classificação final.

6. CRONOGRAMA E RUBRICA DE AVALIAÇÃO

Data	Atividade	Valor
06/04/2026	Construção da especificação técnica, arquitetura e documentação do projeto	0,2 pt
13/04/2026	Dataset + análise exploratória + tratamento + modelo inicial	0,3 pt
27/04/2026	Tratamento final + modelo otimizado + avaliação completa + Interface + entrega final com modelo rodando	0,5 pt

Total: 1,0 ponto

7. CRITÉRIOS DE DESCLASSIFICAÇÃO OU PERDA DE PONTOS

- Vibe Coding (uso de IA sem validação)
- Código que não executa.
- Ausência de explicação clara do que foi feito.
- Apresentação de resultados sem interpretação clínica ou técnica.
- Cópia de código sem compreensão ou referência.
- Dataset com menos de 2000 registros ou sem relação realista com as variáveis clínicas.

8. RESULTADOS ESPERADOS AO FINAL DO PROJETO

Ao concluir o trabalho, o aluno estará apto a:

- Entender um problema real de negócio na área da saúde.
- Trabalhar com dados tabulares (coleta, limpeza e análise).

- Treinar, avaliar e interpretar um modelo de Machine Learning.
- Desenvolver uma solução funcional e apresentá-la (vídeo pitch).
- Tomar decisões técnicas fundamentadas (escolha de algoritmo, métricas e arquitetura).

9. RECOMENDAÇÕES PARA PREPARAÇÃO

- Utilizar Python 3.10+ com as bibliotecas: pandas, numpy, scikit-learn, matplotlib, seaborn e joblib.
- Organizar o projeto em um repositório GitHub (pasta src/, data/, models/, notebooks/).
- Documentar todas as decisões no README.md.
- Preparar o vídeo pitch (apresentar a gravação da demonstração do sistema na última aula).

Dica de ouro: O modelo sugerido (Random Forest) oferece excelente desempenho e interpretabilidade para este tipo de dado tabular.

Este documento serve como referência única e oficial do projeto. Qualquer dúvida deve ser direcionada ao professor durante as aulas.

Boa sorte e excelente desenvolvimento!